



UNIVERSIDAD
COMPLUTENSE
MADRID

DEEP LEARNING Y TELEDETECCIÓN PARA LA PREVENCIÓN DE INCENDIOS FORESTALES EN CANARIAS

TFM

Máster en Big Data, Data Science & IA



José Andrés Ramos Mendoza



Índice

1. Introducción.....	1
1.1 Contexto y motivación.....	1
1.2 Definición del problema y enfoque tecnológico	1
1.3 Productivización y valor diferencial (MLOps)	2
1.4 Estructura de la memoria.....	3
2. Metodología y Data Engineering	3
2.1 Arquitectura de ingesta y fuentes de los datos	3
2.2 Procesamiento espacial	4
2.3 Análisis exploratorio de los datos (EDA)	5
2.4 Cálculo de la variable objetivo (<i>Ground Truth</i>).....	6
2.5 Estandarización y exportación del <i>dataset</i> final	7
3. Modelización y Deep Learning	8
3.1 Definición y distribución de la variable objetivo	8
3.2 Diseño de la red neuronal	9
3.3 Entrenamiento.....	12
3.4 Evaluación de los resultados	12
4. Productivización y arquitectura MLOps	13
4.1 Ingesta espaciotemporal y procesamiento de la imagen	13
4.2 Inferencia, reconstrucción y automatización	14
4.3 Frontend operativo.....	15
5. Conclusiones y mejoras futuras	16
5.1 Conclusiones del trabajo	16
5.2 Líneas de mejora	17
Bibliografía	19

1. Introducción

1.1 Contexto y motivación

Los incendios forestales en el archipiélago canario representan uno de los mayores desafíos para la protección civil y la conservación medioambiental. La compleja orografía volcánica, sumada a los microclimas insulares y a episodios cada vez más frecuentes de estrés hídrico, exige herramientas de anticipación precisas para la gestión de emergencias. En la actualidad, la coordinación de recursos tácticos requiere sistemas dinámicos que superen las limitaciones de los índices de riesgo tradicionales, los cuales suelen depender de mediciones estáticas o de actualizaciones manuales.

Este TFM nace con la vocación de cubrir esa brecha operativa, diseñando una solución tecnológica orientada a los centros de coordinación de emergencias insulares (como CECOPIN) y a los equipos de intervención en campo. El propósito es proporcionar un sistema de apoyo a la toma de decisiones que traduzca la complejidad algorítmica en información visual, directa y accionable, cumpliendo con el objetivo de que los resultados puedan ser comprendidos por un equipo de "negocio" o, en este caso, de coordinación de emergencias.

1.2 Definición del problema y enfoque tecnológico

El desarrollo de este proyecto se aleja del análisis de conjuntos de datos prefabricados, estáticos o ampliamente conocidos en el ámbito académico. En su lugar, se ha optado por un enfoque integral de Data Engineering y Machine Learning para construir una base de datos propia y viva. El sistema propuesto ingiere y procesa de forma autónoma dos flujos de datos diametralmente opuestos:

- **Datos espaciales (Copernicus / Sentinel-2):** Tensores tridimensionales contruidos mediante el apilamiento de bandas multiespectrales, que capturan la reflectancia del terreno, permitiendo calcular el estrés

hídrico de la biomasa forestal mediante índices espectrales (NDVI, NDWI, etc.). [Figura 1]

- **Datos meteorológicos (AEMET / Open-Meteo):** Vectores termodinámicos unidimensionales que recogen la temperatura, humedad relativa y velocidad del viento, interpolados geográficamente sobre la topografía insular.




Figura 1. Representación en falso color de La Gomera (izq.) e índice NDVI de Tenerife.

Para procesar esta cantidad de información, se ha diseñado una red neuronal profunda de arquitectura multimodal (**Late Fusion**) ^[6]. Este modelo cuenta con una rama convolucional (CNN) para la visión artificial y un perceptrón multicapa (MLP) para el clima, fusionando ambas inferencias para emitir una probabilidad continua de riesgo de incendio (de 0.0 a 1.0).

1.3 Productivización y valor diferencial (MLOps)

Más allá de la precisión matemática del modelo (evaluada mediante el Error Absoluto Medio (MAE) y el Error Cuadrático Medio (MSE), el valor diferencial de este proyecto radica en su puesta en producción.

El ecosistema no finaliza en un entorno de desarrollo aislado, sino que se ha productivizado mediante un pipeline automatizado de Integración y Despliegue Continuo (CI/CD) alojado en GitHub Actions. Este robot operativo se ejecuta diariamente para:

- Extraer telemetría satelital y meteorológica en tiempo real.
- Aplicar el filtrado de datos espaciales y el escalado de los datos.
- Ejecutar las inferencias con el modelo Late Fusion.

- Renderizar y desplegar una cartografía predictiva interactiva en un visor web sin necesidad de intervención humana.

1.4 Estructura de la memoria

Esta memoria se centrará en la arquitectura técnica, las transformaciones de datos, la justificación del modelo predictivo y la discusión operativa de los resultados. Todo el código fuente en lenguaje Python, así como los análisis preliminares exhaustivos de los conjuntos de datos, se adjuntarán como anexos independientes.

2. Metodología y Data Engineering

En este proyecto se ha diseñado un *pipeline* de extracción, transformación y carga (ETL) capaz de generar un *dataset* propio, fusionando fuentes heterogéneas para capturar la realidad geoespacial y climática del archipiélago canario.

2.1 Arquitectura de ingesta y fuentes de los datos

Para modelar el riesgo de incendio forestal, es imperativo cruzar el estado físico de la biomasa con las condiciones termodinámicas de la atmósfera en un instante preciso. Para ello, se diseñó la siguiente lógica de ingesta sincronizada:

- **Calendario satelital:** En primer lugar, se obtuvieron las coordenadas geográficas de cada estación de AEMET en Canarias. Utilizando la API de Google Earth Engine, se consultó el catálogo histórico del satélite Sentinel-2 (Copernicus) para extraer el calendario exacto de fechas en las que el satélite sobrevoló cada estación. ^{[1][2]}
- **Descarga condicionada (clima):** Con este calendario, se interrogó la API de AEMET para descargar las series de temperatura máxima, humedad relativa media y velocidad media del viento exclusivamente en los días donde existía una imagen satelital válida para esa coordenada. ^[3]
- **Descarga condicionada (satélite):** Paralelamente, se extrajeron parches espaciales de 64x64 píxeles (resolución de 10 m/px) centrados en cada estación para esas fechas, descargando seis bandas multiespectrales (Azul, Verde, Rojo, NIR B8, SWIR B11 y SWIR B12).

En total se obtuvieron 18916 observaciones que constituyen el *dataset* bruto [Figura 2].




Figura 2. Esquema conceptual del proceso de creación del *dataset*.

2.2 Procesamiento espacial

Para optimizar los tiempos de computación y los posibles falsos positivos en zonas donde físicamente no puede propagarse un incendio (océano, asfalto o roca desnuda), se ha programado un sistema de limpieza dinámico para cada parche. Mediante operaciones matemáticas entre las bandas, se calculan tres índices por cada píxel: ^[4]

- NDWI: Aísla los píxeles de masas de agua (océano, embalses, etc.).

$$\text{NDWI} = \frac{\text{B3} - \text{B8}}{\text{B3} + \text{B8}}$$

- **NDVI:** Discrimina la presencia de biomasa fotosintéticamente activa, descartando núcleos urbanos, terrenos volcánicos áridos, rocas, etc.

$$\text{NDVI} = \frac{\text{B8} - \text{B4}}{\text{B8} + \text{B4}}$$

- **NDMI:** Evalúa el estrés hídrico de la cubierta vegetal detectada.

$$\text{NDMI} = \frac{\text{B8} - \text{B11}}{\text{B8} + \text{B11}}$$

De esta manera cada parche asociado a su correspondiente estación y fecha, tendrá únicamente los píxeles asociados a vegetación viva [Figura 3]. Finalmente se apila en un tensor tridimensional de dimensiones (64, 64, 6), listo para la red neuronal.



Figura 3. Ejemplo visual de cómo actúa el filtrado para la estación de la bahía de San Sebastián de La Gomera (20/01/2023). Izq. Color verdadero; Ctro. Píxeles anulados (negro); Dcha. Índice NDMI sobre los píxeles filtrados.

2.3 Análisis exploratorio de los datos (EDA)

Se auditó la calidad de los datos meteorológicos sobre el conjunto sincronizado de 18.476 observaciones. Se aplicó un filtro estricto de límites físicos para descartar mediciones climáticamente imposibles (ej. Humedades relativas y vientos negativos), el cual confirmó la alta fiabilidad de los registros históricos de la AEMET al arrojar un total de 0 anomalías absolutas.

Sin embargo, el análisis detectó la presencia de 1.604 valores nulos (**NaN**). En estas ocasiones, el satélite disponía de un parche de biomasa válido, pero la tabla carecía del vector termodinámico asociado. Descartar estos registros

incompletos habría supuesto la pérdida de valiosos tensores satelitales, reduciendo la capacidad de generalización del modelo.

Para solventar este problema, se implementó un algoritmo **KNNImputer**.^[5] Este método multivariante deduce el estado atmosférico analizando los 5 días más similares (`n_neighbors=5`), aplicando una ponderación por distancia (`weights="distance"`) para otorgar mayor relevancia a los registros más idénticos.

Adicionalmente, la arquitectura de imputación se encapsuló iterativamente por estación. Al aislar el contexto geográfico, se evita mezclar los microclimas del archipiélago (impidiendo que un dato nulo en la cumbre se rellene con temperaturas de la costa).

2.4 Cálculo de la variable objetivo (*Ground Truth*)

En este proyecto aplicamos técnicas de Feature Engineering para construir la variable objetivo continua que el modelo debía aprender a predecir. Para que la salida de la red tuviera valor operativo y sentido físico en un contexto de emergencias, el Índice de Riesgo Total (0.0 a 1.0) se formuló algorítmicamente de la siguiente forma:

A) Riesgo Meteorológico (35% del peso total):

Se calculó la peligrosidad atmosférica normalizando las variables históricas de la AEMET mediante umbrales tácticos operativos.

- Temperatura: Se acotó en un rango de 15°C (riesgo 0) a 40°C (riesgo máximo 1).
- Humedad Relativa: Se escaló de forma inversa, asumiendo riesgo 0 a partir del 80% de humedad, y riesgo máximo cuando cae por debajo del 20%.
- Viento: Se linealizó de 0 a 50 km/h (límite de riesgo máximo).

El riesgo meteorológico de un día concreto se definió como la media aritmética de estos tres factores normalizados.

B) Riesgo del combustible (65% del peso total):

Un incendio no puede propagarse, por muy adversa que sea la meteorología, si no hay masa vegetal disponible. Por ello, el algoritmo recorrió las matrices tridimensionales aplicando los filtros. Tras aplicarlos, se evaluó exclusivamente el estado de los píxeles con biomasa forestal válida. Sobre estos píxeles, se calculó el NDMI. Matemáticamente, este índice oscila entre -1 y 1. El algoritmo invirtió y reescaló este valor para que 1 representara un nivel crítico de desecación de la vegetación y 0 representara una cubierta totalmente saturada de agua. Si un parche satelital carecía de biomasa (ej. 100% de píxeles de mar o asfalto absoluto), se penalizaba asignándole un riesgo de 0.

C) Riesgo Total:

Finalmente, se consolidó la variable objetivo aplicando una ponderación asimétrica:

$$R_{Total} = (0.35 * R_{meteo}) + (0.65 * R_{combustible})$$

Esta fórmula traslada un principio básico de la extinción forestal al código: el estado físico estructural del bosque (sequedad de la biomasa) condiciona la propagación con mayor contundencia que la fotografía meteorológica puntual del día. De este modo, la variable objetivo a predecir cuenta con una solidez física que respalda las predicciones del modelo ante el equipo de coordinación de emergencias.

2.5 Estandarización y exportación del dataset final

Tras resolver los valores nulos, las variables atmosféricas históricas presentaban magnitudes y varianzas dispares. Además, el clima canario registra eventos extremos u outliers (olas de calor saharianas en invierno, ráfagas de viento fuerte) que desestabilizarían a la red neuronal durante el entrenamiento si se normalizaran de forma estándar.

Para proteger matemáticamente al modelo predictivo, se aplicó un preprocesamiento mediante **RobustScaler**^[5]. El objeto resultante de esta

transformación matemática (`robust_scaler_meteo.pkl`) se exportó para poder ser utilizado posteriormente en la fase de producción.

Finalmente, el *pipeline* de transformación consolida el trabajo empaquetando los cerca de 20.000 tensores espaciales en estructuras binarias eficientes (.npy) (carpeta `tensores_satelite`) y volcando la información meteorológica emparejada y escalada en un archivo `dataset_final_tfm.csv`.

3. Modelización y Machine Learning

3.1 Definición y distribución de la variable objetivo

Para que el modelo actúe como un sistema de alerta temprana útil en la coordinación táctica de emergencias, el riesgo se modeló como un índice continuo en un rango de 0.0 a 1.0.

El análisis de la variable objetivo revela un comportamiento marcadamente bimodal en la telemetría del archipiélago canario. Tal y como se observa en la *Figura 4*, existe un primer pico de frecuencia en el extremo izquierdo (en torno a 0.05) que aísla matemáticamente los escenarios de peligro nulo, caracterizados por alta humedad y ausencia de estrés hídrico. No obstante, la masa principal de observaciones conforma una extensa campana en el sector derecho, situando el riesgo medio en un índice de 0.35. Esta topología de los datos justifica la necesidad de configurar la red neuronal con una función de coste basada en el Error Cuadrático Medio (MSE) y una salida de regresión lineal, permitiendo al algoritmo capturar el espectro completo de matices intermedios del peligro físico.




Figura 4. Frecuencia de la variable objetivo.

3.2 Diseño de la red neuronal

La predicción de incendios forestales requiere cruzar la distribución espacial y estado de salud de la biomasa (imágenes) y las condiciones del aire (datos tabulares). Para ello se ha diseñado una red neuronal profunda de arquitectura multimodal, conocida en la literatura científica como Late Fusion. Esta topología permite procesar cada tipo de dato por separado utilizando el algoritmo óptimo para su naturaleza, fusionando el conocimiento únicamente en la capa final para emitir el veredicto de riesgo. Esto es, el modelo se divide en dos ramas de procesamiento paralelo:

- **Rama de visión artificial (CNN):** Compuesta por capas convolucionales y de agrupación espacial (MaxPooling). Ingiere los tensores satelitales de (64, 64, 6), extrayendo patrones topográficos, densidad de la cubierta vegetal y estrés hídrico de la zona evaluada.
- **Rama meteorológica (MLP):** Un perceptrón multicapa que procesa simultáneamente el vector con las mediciones meteorológicas estandarizadas (temperatura, humedad, viento).

Al final de ambas ramas, éstas se concatenan en un bloque denso común. En este punto, la red correlaciona, por ejemplo, que una alta densidad de

vegetación seca (detectada por la CNN) combinada con viento, baja humedad y altas temperaturas (detectadas por el MLP) disparan críticamente la probabilidad de ignición [Figura 5].




Figura 5. Esquema conceptual de la red neuronal creada para el modelo

3.3 Entrenamiento

Las muestras del conjunto de datos se dividieron reservando un 20% estricto para el conjunto test. Del 80% restante, se utilizó un 80% para entrenamiento y un 20% para validación. El modelo se compiló utilizando el optimizador Adam y configurando el MSE como función de coste debido a la naturaleza continua de la variable objetivo.

Para garantizar que la red no genere overfitting, se implementó un mecanismo de Early Stopping que evalúa constantemente el comportamiento del modelo y detiene automáticamente el entrenamiento si el error de validación no mejora durante 5 iteraciones consecutivas (epochs). Durante esta fase, el entrenamiento se detuvo automáticamente en la época 27 de 50, tomando la iteración 22 como la mejor.

3.4 Evaluación de los resultados

El modelo se auditó midiendo su desviación exacta frente a la verdad física del entorno sobre el conjunto test. Los resultados finales arrojaron un MSE de apenas 0.0019 y un MAE de 0.0228. Esto indica que la red neuronal se equivoca de media un 2,28% al calcular el nivel de peligro. Esta mínima desviación nos asegura un modelo predictivo altamente fiable para anticipar escenarios críticos. Para ilustrar visualmente la precisión de las inferencias, se generó un gráfico de dispersión cruzando la variable objetivo del *dataset* frente a las predicciones emitidas por el modelo. [Figura 6]




Figura 6. Dispersión de la variable objetivo real frente a la predicción del modelo.

El análisis de esta distribución visual revela una correlación directa con la naturaleza bimodal de la variable objetivo analizada en el apartado 3.1. La nube de observaciones no es continua, sino que presenta una división clara con una zona de mínima densidad en torno al valor 0.2. Este valle predictivo es el reflejo exacto de la escasez de muestras de entrenamiento en ese mismo rango estadístico.

A la izquierda de este umbral (riesgo inferior a 0.2), se concentra el primer clúster correspondiente a escenarios de peligro nulo. En esta franja el modelo presenta una ligera dispersión, un comportamiento esperable debido a la alta variabilidad de factores (distintos tipos de bosque y topografías) que pueden coexistir bajo condiciones de alta humedad en Canarias.

Sin embargo, el verdadero valor operativo del sistema emerge en la mitad derecha de la gráfica. Superada la barrera del 0.25, que coincide con la campana principal de datos, las predicciones se agrupan de forma densa y excepcionalmente precisa a lo largo de la línea de igualdad (donde la realidad y la predicción coinciden). Esto es, el sistema reduce drásticamente su margen de error y acierta con contundencia precisamente en los escenarios de alto estrés hídrico y térmico

4. Productivización y arquitectura MLOps

Un modelo predictivo de valor se manifiesta cuando es capaz de operar fuera de un entorno de desarrollo aislado, permitiendo ingerir nuevos datos en tiempo real para devolver estimaciones procesables. Con el objetivo de transferir este modelo a un plano operativo, se diseñó un flujo completo de MLOps que transforma la red neuronal Late Fusion en un sistema de alerta temprana continuo.

4.1 Ingesta espaciotemporal y procesamiento de la imagen

Para que el sistema emita predicciones a futuro, el *pipeline* automatiza la descarga de telemetría y replica de forma dinámica la geometría del entrenamiento. En primer lugar, el código interroga a la API de Google Earth

Engine ^[2] para descargar la imagen multispectral de la constelación Sentinel-2 más reciente disponible para cada isla. Una vez delimitada la biomasa válida mediante los filtros diseñados previamente, un algoritmo de ventana deslizante recorre la topografía insular extrayendo parches espaciales de 64x64 píxeles. Para garantizar la continuidad de la predicción y evitar cortes bruscos en el mapa, la ventana avanza aplicando un solape de 8 píxeles entre cuadrículas adyacentes. De forma paralela, el sistema se conecta a la API de Open Meteo ^[7] para extraer las previsiones meteorológicas calculadas por el modelo numérico de alta resolución HARMONIE-AROME de la AEMET. El código genera una malla sobre el perímetro de la isla y, mediante técnicas de interpolación espacial bilineal, asigna a cada parche geográfico de 64x64 su microclima (temperatura, humedad y viento) estimado para las horas centrales del día, fusionando así ambas naturalezas de datos. [Figura 7]




Figura 7. Ejemplo conceptual de ventana deslizante e interpolación de la meteorología

4.2 Inferencia, reconstrucción y automatización

Con los tensores de cada ventana estructurados, la red neuronal Late Fusion evalúa los miles de parches generados y calcula una probabilidad de incendio independiente para cada uno de ellos. Dado que la técnica de ventana

deslizante produce intersecciones espaciales debido al solape de 8 píxeles, un mismo punto geográfico es evaluado desde múltiples encuadres. Para resolver esta redundancia topológica, el sistema aplica una función de promediado matricial durante la reconstrucción cartográfica: el riesgo definitivo asignado a cada píxel individual equivale a la media aritmética de todos los parches superpuestos que lo contienen.

Para eliminar la necesidad de intervención humana, todo este flujo de reconstrucción cartográfica se orquestó mediante un Trabajo de Integración Continua (CI/CD) alojado en GitHub. A través de un archivo `.yaml`, una máquina virtual ejecuta diariamente el script central (Anexo D), realiza las inferencias para todo el archipiélago y exporta las nuevas matrices a formatos ligeros (JSON y PNG) optimizados para su consumo web.

4.3 Frontend operativo

Para que el equipo de coordinación de emergencias pueda interpretar los resultados rápidamente, la última fase del *pipeline* empuja los datos procesados a un visor web cartográfico interactivo desarrollado en HTML, CSS y JavaScript (utilizando la librería Leaflet) ^[8]. [Figura 8]

El mapa despliega el riesgo de incendio simultáneo sobre todas las islas del archipiélago bajo un mapa de calor, dotando al operador de una visión macroscópica esencial para anticipar futuros escenarios. Las probabilidades numéricas se traducen a una escala de peligro análoga a la de la AEMET (desde nivel Muy Bajo hasta Extremo).

Además, mediante herramientas de Tooltip, el usuario puede posicionar el cursor sobre cualquier hectárea forestal para obtener una lectura instantánea del riesgo porcentual y de los factores exactos que lo provocan (temperatura, humedad relativa y viento previstos), todo ello informando claramente sobre el desfase temporal de la imagen satelital debido a la posible cobertura nubosa.

Esta arquitectura integral convierte este TFM en una solución de software que se tiene un alto potencial de mejora, pero que está lista para producción,

proporcionando a los gestores operativos una base empírica, visual y robusta para preposicionar recursos de extinción.




Figura 8. Captura del visor web asociado al modelo. [9]

5. Conclusiones y mejoras futuras

5.1 Conclusiones del trabajo

El desarrollo de este TFM ha validado empíricamente la viabilidad de la tecnología de Deep Learning multimodal para la gestión de riesgos ambientales complejos. El diseño de la red neuronal Late Fusion ha permitido respetar rigurosamente la topología de la biomasa forestal, cruzándola en tiempo real con las condiciones atmosféricas de alta resolución.

Un hallazgo analítico de gran relevancia es la altísima fidelidad con la que el modelo ha interiorizado el comportamiento del clima en Canarias. Al observar las gráficas del apartado 3, tanto la variable objetivo (Ground Truth) como las predicciones de la red presentan una marcada distribución bimodal, separadas por un profundo mínimo estadístico en torno al 20% (0.2) de probabilidad. Lejos de ser un sesgo algorítmico, este patrón captura y refleja matemáticamente la creciente polarización climática de Canarias: los días de meteorología "moderada" o de transición son cada vez más escasos. El modelo ha aprendido que la realidad insular actual se divide en extremos, saltando drásticamente de

escenarios de alta humedad atlántica (riesgo muy bajo) a severas irrupciones secas y cálidas por calima (riesgos altos). La IA, por tanto, no solo calcula un índice de incendios, sino que ha parametrizado empíricamente esta radicalización del clima local.

Por otro lado, el hito más destacable del proyecto no reside únicamente en su robustez matemática con un Error Absoluto Medio (MAE) de apenas el 2,28%, sino en la exitosa traslación del algoritmo a un entorno operativo real. La implementación de la arquitectura MLOps mediante integración continua, junto con el visor cartográfico web ^[9], convierte esta inteligencia artificial en una herramienta táctica de apoyo a la decisión. En salas de coordinación de emergencias, disponer de un mapa interactivo diario que traduce tensores complejos a la escala de alerta visual de la AEMET facilita enormemente el preposicionamiento preventivo de los recursos de extinción sobre el terreno.

5.2 Líneas de mejora

Desde el punto de vista técnico, el sistema establece una arquitectura base altamente escalable. Se proponen las siguientes iteraciones para perfeccionar la robustez del modelo en futuras investigaciones:

- **Corrección del desbalanceo mediante Sample Weighting:** Tal y como se documentó durante el entrenamiento, la climatología canaria genera una escasez de muestras en los valores de riesgo intermedios (valle estadístico en torno al índice 0.2). En versiones posteriores, se aplicarán técnicas de ponderación en la función de coste para obligar a la red a penalizar con mayor severidad los errores en este rango minoritario, evitando el sobreajuste a los escenarios extremos.
- **Inclusión de variables orográficas (MDE):** El comportamiento dinámico y la velocidad de propagación del fuego están fuertemente condicionados por los grandes desniveles y barrancos. La integración de un Modelo Digital de Elevaciones como una banda adicional en el tensor espacial aportaría a la red la capacidad de inferir el peligro derivado de la orografía.

- **Resiliencia a la nubosidad mediante radar (SAR):** Actualmente, la sensibilidad del sistema depende de los sensores ópticos de Sentinel-2, los cuales quedan inoperativos bajo el mar de nubes de los vientos alisios. Híbrido la entrada con datos de radar de apertura sintética (Sentinel-1) permitiría evaluar la estructura de la vegetación traspasando la nubosidad, garantizando una telemetría ininterrumpida.
- **Aumento de la resolución espaciotemporal (Constelación Islas Canarias):** Actualmente, el modelo está limitado por la resolución espacial (10m/px) y el tiempo de revisita (~5 días) de Sentinel-2. Una mejora sustancial consistiría en la futura integración de la telemetría procedente de la Constelación Islas Canarias, el programa de pequeños satélites de observación de la Tierra recientemente impulsado por el Instituto de Astrofísica de Canarias (IAC) y el Cabildo de Tenerife. La ingesta de estos datos permitiría reducir drásticamente el tamaño de píxel y la latencia temporal, dotando al algoritmo de una capacidad casi continua para monitorizar a las islas.^[10]
- **Módulo de detección y monitorización en tiempo real:** Como evolución natural del sistema predictivo, se plantea el desarrollo de una arquitectura neuronal paralela orientada a la fase de emergencia activa. Este nuevo modelo procesaría anomalías térmicas a través de las bandas SWIR del Sentinel-2. Su integración directa en el visor web actual transformaría la plataforma en una solución operativa integral, unificando en una sola interfaz tanto en la prevención como en la extinción de incendios forestales.

Bibliografía

- [1] Agencia Espacial Europea (ESA). (2024). *Sentinel-2 User Handbook*. Copernicus Open Access Hub. Recuperado de: <https://sentinels.copernicus.eu>
- [2] Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*.
- [3] Agencia Estatal de Meteorología (AEMET). (2024). *AEMET OpenData: Datos Climatológicos y Modelos Numéricos*. Ministerio para la Transición Ecológica y el Reto Demográfico. Recuperado de: <https://opendata.aemet.es/>
- [4] Chuvieco, E. (2010). *Teledetección ambiental: La observación de la Tierra desde el espacio* (3.ª ed.). Ariel Ciencia.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [6] Chollet, F., et al. (2015). *Keras: Deep Learning for humans* [Software]. Recuperado de: <https://keras.io>
- [7] Zippenfenig, P. (2023). *Open-Meteo.com Weather API* [Software]. Zenodo. <https://doi.org/10.5281/ZENODO.7970649>
- [8] Agafonkin, V. (2024). *Leaflet: An open-source JavaScript library for mobile-friendly interactive maps*. Recuperado de: <https://leafletjs.com/>
- [9] Prevención de incendios forestales. (s. f.). <https://canarywildfirerisk.es/>
- [10] El Cabildo y el IAC fabricarán la primera constelación de satélites canaria para observar y proteger el Archipiélago desde el espacio. (s. f.). Instituto de Astrofísica de Canarias · IAC. <https://www.iac.es/es/divulgacion/noticias/el-cabildo-y-el-iac-fabricaran-la-primera-constelacion-de-satelites-canaria-para-observar-y-proteger-el>

ANEXOS

Anexo A. Repositorio GitHub

Todo el código fuente desarrollado, incluyendo el *pipeline* de extracción, notebooks de colab y la automatización MLOps, se encuentra disponible en acceso abierto en el repositorio público:

- **Enlace al repositorio:**
https://github.com/joseandres03/sentinel2meteo_IA_wildfire_risk
- **Enlace a la web del visor:**
<https://canarywildfirerisk.es/>

Anexo B. Flujo de ejecución (Cuadernos Colab)

Para facilitar la evaluación por parte del tribunal sin necesidad de ejecutar las pesadas descargas espaciales desde cero, se ha diseñado un flujo de evaluación en los cuadernos (notebooks/):

1. **Cuaderno 1 (ETL):** Demuestra la conexión a las APIs y la generación del catálogo espacial.
2. **Cuaderno 2 (EDA):** Descarga el *dataset* ya ensamblado desde la nube (gdown) y permite auditar en segundos la limpieza, la interpolación espacial y el escalado.
3. **Cuaderno 3 (Deep Learning):** Carga los tensores en memoria RAM e inicia el entrenamiento de la red *Late Fusion*, generando las métricas de evaluación.

Anexo C. Arquitectura neuronal

El modelo consta de 1.075.297 parámetros entrenables, convergiendo en capas de concatenación y regularización (*Dropout* 0.3 y 0.2) antes de la salida lineal probabilística.

ANEXOS

Layer (type)	Output Shape	Param #	Connected to
input_satelite (InputLayer)	(None, 64, 64, 6)	0	-
rescaling (Rescaling)	(None, 64, 64, 6)	0	input_satelite[0]...
conv2d (Conv2D)	(None, 64, 64, 32)	1,760	rescaling[0][0]
max_pooling2d (MaxPooling2D)	(None, 32, 32, 32)	0	conv2d[0][0]
conv2d_1 (Conv2D)	(None, 32, 32, 64)	18,496	max_pooling2d[0]...
max_pooling2d_1 (MaxPooling2D)	(None, 16, 16, 64)	0	conv2d_1[0][0]
flatten (Flatten)	(None, 16384)	0	max_pooling2d_1[...
input_meteo (InputLayer)	(None, 3)	0	-
dense (Dense)	(None, 64)	1,048,640	flatten[0][0]
dense_1 (Dense)	(None, 32)	128	input_meteo[0][0]
concatenate (Concatenate)	(None, 96)	0	dense[0][0], dense_1[0][0]
dropout (Dropout)	(None, 96)	0	concatenate[0][0]
dense_2 (Dense)	(None, 64)	6,208	dropout[0][0]
dropout_1 (Dropout)	(None, 64)	0	dense_2[0][0]
prediccion_riesgo (Dense)	(None, 1)	65	dropout_1[0][0]
Total params: 1,075,297 (4.10 MB) Trainable params: 1,075,297 (4.10 MB) Non-trainable params: 0 (0.00 B)			

```
Epoch 27: early stopping
Restoring model weights from the end of the best epoch: 22.

Evaluando el rendimiento sobre los datos de Test...

RESULTADOS DE LA PREDICCIÓN
Error Cuadrático Medio (MSE): 0.0019
Error Absoluto Medio (MAE): 0.0228
La red se equivoca un 2.28% al predecir el peligro real.
```

Anexo D. Flujo de automatización MLOps (GitHub Actions)

Para ilustrar el ciclo de vida del dato en el entorno de producción, el siguiente diagrama detalla la orquestación del *pipeline* de Integración y Despliegue Continuo (CI/CD). Este flujo automatizado garantiza que el visor cartográfico

ANEXOS

web disponga de inferencias actualizadas diariamente sin requerir intervención manual.

